

王子状

男 | 年龄：20岁 | 籍贯：开封 | 18637821268 | 2796854653@qq.com

求职意向：大模型应用开发



教育经历

河南工业大学 本科 软件工程

2023-2027

- 曾获奖项：CET-4 | PAT乙级二等奖 | 蓝桥杯c++组省级二等奖
- 校园经历：院级学生会副部长，负责组织策划百人规模校园活动，具备极强的跨部门沟通与团队协作统筹能力。

项目经历

基于多智能体（Multi-Agent）架构的智能旅行规划系统 Agent开发

2025.08-2025.11

内容：

核心技术栈：Python, LangChain, LangGraph, OpenAI/DeepSeek API, FastAPI, Vue3

项目描述：本项目是一个基于流式状态机（LangGraph）构建的 AI 旅行规划助手。通过将复杂旅行规划任务拆解，调度多个垂直领域的 Agent（天气、景点、住宿等）进行协同工作，并引入 Function Calling 机制挂载外部高德 REST API（天气/POI），赋予 Agent 实时的 Grounding（外部挂载）能力，从根本上压制了大模型的地点捏造的“幻觉”，最终为用户生成结构化、个性化的多日行程安排。

业绩：

- 多智能体架构设计 (Multi-Agent with LangGraph)：**构建基于 StateGraph 的多智能体工作流。拆解旅行规划任务，设计了景点、天气、酒店检索 Agent 以及统筹 Planner Agent。定义全局 TripPlannerState 解决各个 Agent 之间的数据传递和上下文隔离问题。
- 工具调用与解决大模型幻觉 (Tool Calling)：**基于 LangChain Tools 封装高德地图 REST API（POI搜索、天气查询），利用大模型的 bind_tools 机制赋予大模型联网与实时检索能力，从根本上降低了地点捏造等“幻觉”现象。
- Agent 自决策循环优化：**实现带有大模型自纠错的工具调用循环（Tool Call Loop），设置单节点最多 3 轮的自我迭代调用，保证数据获取的准确性和接口边界的安全。
- Prompt Engineering 与结构化输出控制：**为不同角色的 Agent 设计高鲁棒性的 System Prompt；针对最终 Planner Agent 采用特定指令约束和 Few-shot 示例，确保最终输出高度嵌套的 JSON 结构以供前端可视化渲染。
- 模型兼容与工程化落地：**私有化部署qwen3.5模型，封装 LLM 服务层，实现 OpenAI 规范与多种国产模型（如 DeepSeek 等）的无缝动态切换；利用 FastAPI 提供后端异步高并发接口响应前端请求

企业级全异步智能客服与大模型知识库系统（MilDoc） RAG开发

2025.12-2026.02

内容：

核心技术栈：Python, LangChain, OpenAI API, Milvus, Mineru, 阿里百炼/硅基流动(Rerank), MinIO/OSS, 微信客服原生API, Langfuse

项目描述：基于 Serverless 事件驱动架构与 RAG（检索增强生成）技术构建的企业级私有化智能问答中台。解决通用大模型在垂直企业场景下的知识断层与幻觉问题。

业绩：

- 主导 RAG 检索引擎双路优化，提升问答准确率：**设计 召回 + 重排 的两段式检索架构。使用 Milvus 进行高维向量 Cosine 粗排召回（Top-10），接入阿里云百炼与硅基流动模型进行 Cross-Encoder 二次交叉重排（Top-5），并创“原生向量 Top-1 兜底强保策略”（防止重排泛化导致的绝对匹配丢失），将最终注入提示词的 Top-3 切片相关性召回率提升 30% 以上。

- **攻坚高排版/复杂结构数据的解析难题**：针对传统 PDF 财报中复杂表格、数学公式易丢失的问题，引入视觉大模型底座 MinerU 与微软 MarkItDown 组件，将多模态数据/Office全家桶精准还原为语义连贯的 Markdown 格式，配合 RecursiveCharacterTextSplitter 动态滑窗切割（2048切片/128重叠），大幅提升复杂文档的索引质量。
- **构建 Event-Driven (事件驱动) 知识无缝秒级入库链路**：摒弃传统定时轮询同步机制，打通 MinIO Webhook 与阿里云 MNS 消息队列。当用户在 Admin 控制台上传文件时，即刻触发异步无服务器守护进程（oss_event_handler.py）进行静默解析、向量化及 Milvus 落盘，保障知识零延迟上架。
- **对接企微客服全量生态，强化企业级可观测性**：基于 Flask 与异步并发模型承接企微客服回调，并在大语言模型处理链路上挂载 Langfuse 进行 Tracing 数据埋点。实现 Token 开销看板可视化、微秒级的 RAG 节点追溯及系统调优闭环。

专业技能

- **AI 模型与架构引擎**：熟悉 Multi-Agent 架构设计与图编排（DAG 状态机），深入理解 LangGraph 核心架构（State/Node/Edge）。掌握各种 Agent 推理与协同范式（ReAct / Plan-Execute / Critic 路由），熟练应用 Function Call 机制与 MCP（Model Context Protocol）协议。
- **RAG 与向量检索技术**：熟悉高阶 RAG 优化管线（离线文档解析 / 在线多路召回）。深谙 Milvus ANN 向量检索与主流索引结构（HNSW），熟悉基于 text-embedding-v4 与 DashScope Rerank 的混合检索（Hybrid Retrieval）及召回重排策略。
- **大模型私有化与微调部署**：熟练掌握 vLLM、llama.cpp、Ollama 等前沿推理加速框架，具备私有化主流开源模型（如 Qwen/DeepSeek）的实战能力。了解 LoRA / QLoRA 参数高效微调原理及数据构建管线。
- **核心后端开发**：熟练使用 Python，并基于 FastAPI 开发高并发异步后端，充分掌握 asyncio 异步与协程队列。掌握 PostgreSQL（熟悉 JSONB 与全本检索）、MySQL（MVCC 与索引优化），以及 Redis 缓存层架构。
- **AI Coding 与工程化**：极客型“深度 Vibe Coding 实践者”。熟练将 Claude Code、Cursor 与 MCP 技术融入协同编程开发；掌握 Git 开发流与并了解 Docker / Docker Compose 容器化部署方案。

个人优势

- 持续关注 AI 前沿技术动态，对 Agent、RAG、模型训练等方向保持高密度学习与实践投入。
- 深度 Vibe Coding 实践者，在工作中建立了系统化的 AI Coding 开发流程（Prompt 调优、Skills、MCP），融入日常开发；
- 自驱力强，善于从业务痛点出发主动提出技术方案，具备从 0 到 1 推动项目落地的闭环能力。